

# MAT02034 - Métodos bayesianos para análise de dados

## Introdução ao raciocínio bayesiano

Rodrigo Citton P. dos Reis  
citton.padilha@ufrgs.br

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL  
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA  
DEPARTAMENTO DE ESTATÍSTICA

Porto Alegre, 2022

# Introdução

# Introdução

- ▶ Nesta aula, os elementos básicos da abordagem inferencial bayesiana são introduzidos por meio do problema básico de aprender sobre uma proporção populacional.
- ▶ Antes de coletar os dados, temos crenças sobre o valor da proporção e modelamos nossas crenças em termos de uma **distribuição *a priori***.
- ▶ Após a **observação dos dados**, atualiza-se a crença sobre a proporção calculando a **distribuição *a posteriori***.
- ▶ **Resumimos** esta distribuição de probabilidade para realizar **inferências**.
- ▶ Além disso, pode-se estar interessado em **prever os resultados** prováveis de uma nova amostra retirada da população.

# Aprendendo sobre uma proporção

# Aprendendo sobre uma proporção

- ▶ Suponha que uma pessoa esteja interessada em aprender sobre os **hábitos de sono** dos estudantes universitários.
- ▶ Ela ouve que os médicos recomendam **oito horas de sono** para um adulto médio.
- ▶ **Que proporção de estudantes universitários dormem pelo menos oito horas?**
- ▶ Aqui pensamos em uma **população** composta por todos os estudantes universitários e  $p$  representa a proporção dessa população que dorme (em uma noite típica durante a semana) pelo menos oito horas.
- ▶ Estamos interessados em aprender sobre  $p$ .

# Aprendendo sobre uma proporção

- ▶ O valor de  $p$  é desconhecido.
- ▶ Sob o ponto de vista bayesiano, as crenças de uma pessoa sobre a incerteza de  $p$  são representadas por uma distribuição de probabilidade colocada nesse parâmetro.
- ▶ Essa distribuição reflete a opinião subjetiva *a priori* da pessoa sobre valores plausíveis de  $p$ .
  
- ▶ Uma **amostra aleatória** de estudantes de uma determinada universidade será coletada para aprender sobre essa proporção.
- ▶ Mas primeiro o pesquisador faz algumas pesquisas para aprender sobre os hábitos de sono dos estudantes universitários.
  - ▶ Esta pesquisa a ajudará na construção de uma distribuição *a priori*.

# Aprendendo sobre uma proporção

- ▶ Com base nessa pesquisa, **a pessoa** que faz o estudo **acredita que os estudantes** universitários geralmente **dormem menos de oito horas** e, portanto,  $p$  (a proporção que dorme pelo menos oito horas) é provavelmente menor que 0.5.
- ▶ Após alguma reflexão, seu melhor palpite para o valor de  $p$  é 0.3.
  - ▶ Mas é muito plausível que essa proporção possa ser qualquer valor no intervalo de 0 a 0.5.
- ▶ Uma amostra com 27 estudantes é coletada.
  - ▶ Destes, 11 registram que dormiram pelo menos oito horas na noite anterior.
- ▶ Com base nas informações anteriores e nesses dados observados, o pesquisador está interessado em estimar a proporção  $p$ .

# Aprendendo sobre uma proporção

- ▶ Denote a densidade *a priori* para  $p$  por  $g(p)$ .
- ▶ Se considerarmos um “sucesso” como dormir pelo menos oito horas e tomarmos uma amostra aleatória com  $s$  sucessos e  $f$  falhas, então a **função de verossimilhança** é dada por

$$L(p) \propto p^s(1 - p)^f, \quad 0 < p < 1.$$

- ▶ A densidade *a posteriori* para  $p$ , pela **regra de Bayes**, é obtida, a menos de uma constante de proporcionalidade, multiplicando a densidade *a priori* pela verossimilhança:

$$g(p|\text{dados}) \propto g(p)L(p).$$




## Utilizando uma priori discreta

## Utilizando uma priori discreta

- Uma **abordagem simples** para avaliar uma distribuição priori para  $p$  é escrever uma **lista de valores** de proporção plausíveis e então atribuir **pesos** ( $w$ ) a esses valores.

$p_i$	0.05	0.15	0.25	0.35	0.45	0.55	0.65	0.75	0.85	0.95
$w(p_i)$	1	5.2	8	7.2	4.6	2.1	0.7	0.1	0	0
$g(p_i)$	0.035	0.180	0.277	0.249	0.159	0.073	0.024	0.003	0	0

## Utilizando uma priori discreta



## Utilizando uma priori discreta

- ▶ Lembrando que em nosso exemplo, 11 de 27 alunos dormem um número suficiente de horas ( $\hat{p} = 0.40$ ), então  $s = 11$  e  $f = 16$ , e a função de verossimilhança<sup>1</sup> é

$$L(p) \propto p^{11}(1-p)^{16}, \quad 0 < p < 1.$$


- ▶ A distribuição *a posteriori* é obtida, no caso discreto, da seguinte forma

$$g(p_i|\text{dados}) = \frac{g(p_i)L(p_i)}{\sum_i g(p_i)L(p_i)}, \quad p_i \in \{0.05, 0.15, \dots, 0.95\}.$$

---

<sup>1</sup>Note que a verossimilhança é núcleo de uma densidade beta com parâmetros  $s + 1 = 12$  e  $f + 1 = 17$ .

# Utilizando uma priori discreta



## Utilizando uma priori discreta

$p_i$	0.25	0.35	0.45	0.55	0.65	0.75
$g(p_i)$	0.277	0.249	0.159	0.073	0.024	0.003
$L(p_i) \times 10^{12}$	2389.573	9803.072	10743.374	3939.035	443.747	9.834
$g(p_i \text{dados})$	0.129	0.477	0.334	0.056	0.002	0.000

- ▶ Notamos que a maior parte da probabilidade *a posteriori* está concentrada nos valores  $p = 0.35$  e  $p = 0.45$ .
- ▶ Se combinarmos as probabilidades para os três valores mais prováveis, podemos dizer que a probabilidade *a posteriori* de que  $p$  caia no conjunto 0.25, 0.35, 0.45 é igual a 0.940.

## Utilizando uma priori beta

## Utilizando uma priori beta

- ▶ Como a  $p$  é um parâmetro contínuo, uma abordagem alternativa é construir uma densidade  $g(p)$  no intervalo  $(0, 1)$  que represente as crenças iniciais do pesquisador.
- ▶ Suponha que ele acredite que a proporção tem a mesma probabilidade de ser menor ou maior que  $p = 0.3$ .
  - ▶  $\Pr(p \leq 0.3) = \Pr(p \geq 0.3)$ .
- ▶ Além disso, ela está 90% confiante de que  $p$  é menor que 0.5.
  - ▶  $\Pr(p \leq 0.5) = 0.90$ .



## Utilizando uma priori beta

- Uma **família** conveniente **de densidades** para uma proporção é a **beta**

$$g(p) = \frac{1}{B(a, b)} p^{a-1} (1-p)^{b-1} \\ \propto p^{a-1} (1-p)^{b-1}, \quad p \in (0, 1), a > 0, b > 0,$$

em que  $B(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$  é a chamada função beta e


$\Gamma(t) = \int_0^\infty u^{t-1} e^{-u} du, t > 0$  é a função gama<sup>2</sup>.

- Os **hiperparâmetros**  $a$  e  $b$  são escolhidos para refletir as crenças *a priori* do pesquisador sobre  $p$ .

---

<sup>2</sup> $\Gamma(a) = (a-1)!$  se  $a \in \mathbb{N}$

# Utilizando uma priori beta



## Utilizando uma priori beta

- ▶ A **média** de uma distribuição *a priori* beta é  $m = a/(a + b)$  e a **variância** *a priori* é  $v = m(1 - m)/(a + b + 1)$ 
  - ▶ Na prática é difícil para um pesquisador avaliar os valores de  $m$  e  $v$  para obter os valores dos parâmetros da beta  $a$  e  $b$ .
  - ▶ É mais fácil obter  $a$  e  $b$  indiretamente por meio de declarações sobre os percentis da distribuição ( $p_{0.5} = 0.3$  e  $p_{0.9} = 0.5$  corresponde à dist. beta com  $a = 3.26$  e  $b = 7.19$ )<sup>3</sup>.

---

<sup>3</sup>Veja a função `beta.select` do pacote `LearnBayes` do R.

## Utilizando uma priori beta

- Combinando este dist. *a priori* beta com a função de verossimilhança, temos a dist. *a posteriori* **também é beta**<sup>4</sup> com parâmetros  $a + s$  e  $b + f$


$$g(p|\text{dados}) \propto p^{a+s-1}(1-p)^{b+f-1}, \quad p \in (0, 1),$$

em que  $a + s = 3.26 + 11$  e  $b + f = 7.19 + 16$ .

---

<sup>4</sup>Este é um exemplo de **análise conjugada**, em que as densidades *a priori* e *a posteriori* têm a mesma forma funcional.

# Utilizando uma priori beta



# Utilizando uma priori beta

- ▶ Existem diferentes maneiras de resumir a distribuição beta *a posteriori* **para fazer inferências sobre a proporção de dorminhocos  $p$** .
- ▶ Podemos utilizar a função distribuição acumulada da beta, e a sua inversa, para calcular probabilidades *a posteriori* e construir estimativas intervalares para  $p$ .

## Utilizando uma priori beta

- ▶ É provável que a proporção de pessoas com sono pesado seja maior que 0.5?
  - ▶ Isso é respondido calculando a probabilidade *a posteriori*  $\Pr(p \geq 0.5 | \text{dados})$ :

```
a <- 3.26; b <- 7.19; s <- 11; f <- 16
```

```
pbeta(q = 0.5,  
      shape1 = a+s, shape2 = b+f,  
      lower.tail = FALSE)
```

```
## [1] 0.0690226
```

## Utilizando uma priori beta

- Uma estimativa de intervalo de 90% para  $p$  é encontrada calculando os percentis 5 e 95 da densidade beta:

```
qbeta(p = c(0.05, 0.95),  
      shape1 = a+s, shape2 = b+f)
```

```
## [1] 0.2555267 0.5133608
```

- Um **intervalo de credibilidade** *a posteriori* de 90% para a proporção é (0.256, 0.513).




## Utilizando uma priori beta

- ▶ Esses resumos são “exatos” porque são baseados em funções R para a densidade beta *a posteriori*.
- ▶ Um método alternativo de sumarização de uma densidade *a posteriori* é baseado em **simulação**.
- ▶ Nesse caso, podemos simular um grande número de valores da densidade beta *a posteriori* e resumir a **amostra** (saída) **simulada**.

```
amostra.post <- rbeta(n = 1000,  
                      shape1 = a+s, shape2 = b+f)
```

# Utilizando uma priori beta



## Utilizando uma priori beta

- ▶ A probabilidade de que a proporção seja maior que 0.5 é aproximada (estimada<sup>5</sup> usando a proporção de valores simulados neste intervalo

$$\frac{1}{M} \sum_{j=1}^M I(p^{(j)} \geq 0.5),$$

em que  $M$  é o número de valores simulados,  $p^{(j)}$  é  $j$ -ésimo valor simulado da dist. beta ( $j = 1, \dots, M$ ) com parâmetros  $a + s$  e  $b + f$  e  $I(\cdot)$  é **função indicadora**.

- ▶ Note que para  $M$  “grande”

$$\Pr(p \geq 0.5 | \text{dados}) = E[I(p \geq 0.5) | \text{dados}] \approx \frac{1}{M} \sum_{j=1}^M I(p^{(j)} \geq 0.5).$$

---

<sup>5</sup>estimativa estocástica, ou de Monte Carlo.

## Utilizando uma priori beta

- ▶ No R:

```
sum(amostra.post >= 0.5)/1000
```

```
## [1] 0.078
```

- ▶ Uma estimativa de intervalo de 90% pode ser estimada pelos 5º e 95º quantis amostrais da amostra simulada:

```
quantile(x = amostra.post, probs = c(0.05, 0.95))
```

```
##          5%          95%
```

```
## 0.2603226 0.5167994
```

## Utilizando uma priori beta

- ▶ Observe que esses resumos da densidade *a posteriori* para  $p$  baseados em simulação são aproximadamente iguais aos valores exatos baseados em cálculos da distribuição beta.
- ▶ A aproximação melhora conforme aumentamos o número de valores simulados  $M$ .

# Predição

# Predição

- ▶ Nós nos concentramos em aprender sobre a proporção populacional de pessoas com sono pesado  $p$ .
- ▶ Suponha que nosso pesquisador também esteja interessado em **prever** o número de dorminhocos  $\tilde{y}$  em uma amostra futura de  $m = 20$  alunos.

## Preditiva a posteriori

- ▶ Depois de observarmos os dados e obtermos a distribuição *a posteriori* dos parâmetros, podemos agora usar a distribuição *a posteriori* para gerar **dados futuros** do modelo.
- ▶ Em outras palavras, dada a distribuição *a posteriori* dos parâmetros do modelo, a `\structure{distribuição` *preditiva a posteriori* nos dá uma indicação de como os dados futuros podem parecer, condicional aos dados ( $y$ ) e o modelo ( $L(p)$  e  $g(p)$ ).

## Predição

- Uma vez que temos a distribuição posteriori  $g(p|\text{dados})$ , podemos derivar as previsões ( $\tilde{y}$ ) com base nessa distribuição:

$$f(\tilde{y}|y) = \int f(\tilde{y}, p|y) dp = \int f(\tilde{y}|p, y) g(p|y) dp.$$

- Assumindo que as observações passadas e futuras são **condicionalmente independentes**, dado  $p$ , ou seja,  $f(\tilde{y}|p, y) = f(\tilde{y}|p)$ , nós podemos escrever:

$$f(\tilde{y}|y) = \int f(\tilde{y}|p) g(p|y) dp. \tag{1}$$



# Predição

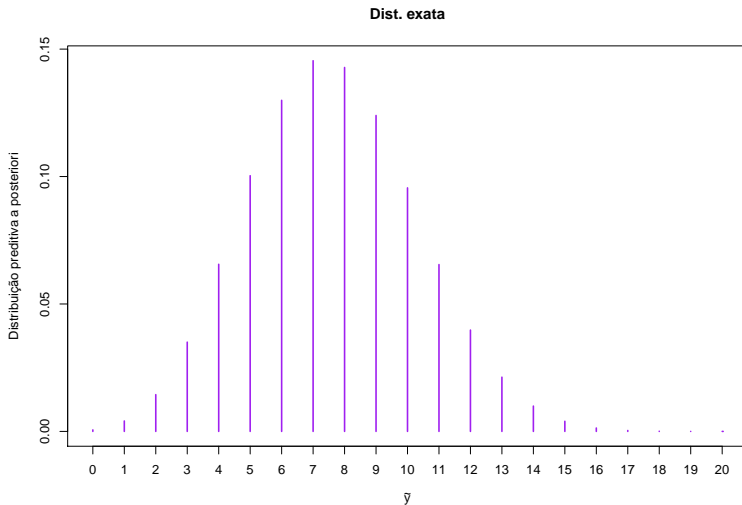
- ▶ Na equação (1), estamos condicionando  $\tilde{y}$  apenas em  $y$ , não condicionamos o que não conhecemos ( $p$ ); integramos os parâmetros desconhecidos.
- ▶ Considerando o modelo anterior (*priori* beta), e um modelo adequado para  $f(\tilde{y}|p)$  a distribuição binomial, de parâmetros  $m = 20$  (ensaios/entrevistados) e  $p$  (probabilidade de ter sono “pesado”).
  - ▶ Neste caso, podemos integrar analiticamente a equação (1) e obter uma expressão de forma fechada para a densidade preditiva,

$$f(\tilde{y}|y) = \binom{m}{\tilde{y}} \frac{B(a + s + \tilde{y}, b + f + m - \tilde{y})}{B(a + s, b + f)}, \tilde{y} = 0, \dots, m, \quad (2)$$

em que  $B(a, b)$  é a função beta.

- ▶ A distribuição em (2) é conhecida como **beta-binomial**.

# Predição



## Predição

- Uma maneira conveniente de calcular uma densidade preditiva para qualquer distribuição *a priori* é por simulação. Note que (1) pode ser aproximada por uma média amostral

$$f(\tilde{y}|y) = \int f(\tilde{y}|p)g(p|y)dp = E[f(\tilde{y}|p)|y] \approx \frac{1}{M} \sum_j^M f(\tilde{y}|p^{(j)}).$$


- Para obter  $\tilde{y}$ , primeiro simulamos, digamos,  $p^{(j)}$  a partir de  $g(p|y)$ , e então simulamos  $\tilde{y}$  a partir da distribuição binomial  $f(\tilde{y}|p^{(j)})$ .

```
M <- 1000000
```

```
p <- rbeta(n = M, shape1 = a + s, shape2 = b + f)
ytilde.sim <- rbinom(n = M, size = m, prob = p)
```

# Predição

Aproximação Monte Carlo



## Próxima aula

- ▶ Modelos de parâmetro único;
- ▶ Modelos de múltiplos parâmetros.

# Por hoje é só!

Sejam tod@s bem-vind@s!

