

MAT02034 - Métodos bayesianos para análise de dados

Modelos bayesianos hierárquicos - exemplo: dados de
mortalidade de câncer

Rodrigo Citton P. dos Reis
citton.padilha@ufrgs.br

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
DEPARTAMENTO DE ESTATÍSTICA

Porto Alegre, 2022

Introdução

Introdução

Nesta aula, através de um exemplo, vamos discutir os seguintes temas:

- ▶ Reparametrização;
- ▶ Gibbs com passos de M-H;
- ▶ O algoritmo M-H passeio aleatório;
- ▶ Parâmetros de *tuning*;
- ▶ Computação no R;
- ▶ Representação gráfica de modelos bayesianos hierárquicos (DAGs).

Exemplo: dados de mortalidade de câncer

Dados de mortalidade de câncer

- ▶ Para ilustrar os métodos descritos nas aulas anteriores (**MCMC e MBH**), considere os dados de mortalidade por câncer analisados por Tsutakawa, Shoop e Marienfeld (1985)¹.
- ▶ Estamos interessados em **estimar simultaneamente as taxas de óbito** por câncer de estômago para homens “em risco” na faixa etária de 45 a 64 anos para as 84 maiores cidades do Missouri.

¹Tsutakawa RK, Shoop GL, Marienfeld CJ. Empirical Bayes estimation of cancer mortality rates. *Stat Med*. 1985 Apr-Jun;4(2):201-12. doi: 10.1002/sim.4780040210.

Dados de mortalidade de câncer

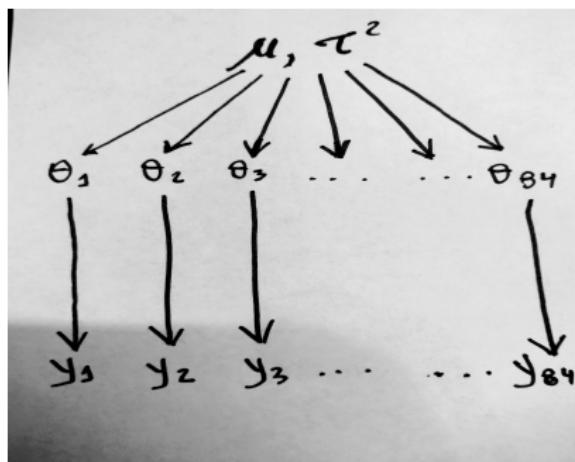
- ▶ Para a i -ésima cidade ($i = 1, \dots, 84$), observa-se o número N_i em risco e o número de óbitos por câncer y_i .
- ▶ Suponha que os $\{y_i\}$ sejam independentes com distribuições binomiais e $p_i = \Pr(Y_i = y_i)$ sejam as respectivas probabilidades de óbito.
- ▶ Se as taxas de mortalidade por câncer não variam significativamente entre as cidades (pequenas ou grandes) e entre os homens nessa faixa etária, então pode ser razoável acreditar *a priori* que as taxas são **intercambiáveis**.

Dados de mortalidade de câncer

- ▶ Essa crença *a priori* pode ser modelada deixando os **logitos (logit)** $\theta_i = \log(p_i/(1 - p_i))$ serem independentes $N(\mu, \tau^2)$, e então atribuindo μ e τ^2 distribuições independentes $N(\mu_0, \sigma_\mu^2)$ e $Gal(a, b)$.
 - ▶ τ^2 é um parâmetro de variância;
 - ▶ $Gal(a, b)$ representa a distribuição **gama invertida**; se $X \sim Gal(a, b)$, então $f(x|a, b) = \frac{b^a}{\Gamma(a)}(1/x)^{a+1}e^{-b/x}$.
 - ▶ $(\mu_0, \sigma_\mu^2, a, b)$ são hiperparâmetros a serem especificados.

DAGs

- Podemos exibir esquematicamente o modelo hierárquico (assim, como outras relações de dependência) por meio de um **grafo acíclico dirigido (*directed acyclic graphs, DAGs*)**.



Dist. a posteriori

Dist. a posteriori

- A distribuição *a posteriori* deste modelo, $g(\theta, \mu, \tau^2, a, b | \mathbf{y})$, é proporcional à

$$\begin{aligned}
 & p(\mathbf{y} | \theta, \mu, \tau^2) \times g_1(\theta | \mu, \tau^2) \times g_2(\mu, \tau^2) \\
 = & \left\{ \prod_{i=1}^n p(y_i | h(\theta_i)) \right\} \times \left\{ \prod_{i=1}^n g_1(\theta_i | \mu, \tau^2) \right\} \times g_2(\mu, \tau^2) \\
 = & \left\{ \prod_{i=1}^n p(y_i | h(\theta_i)) \times g_1(\theta_i | \mu, \tau^2) \right\} \times g_2(\mu, \tau^2).
 \end{aligned}$$

- $h(\theta_i) = \frac{e^{\theta_i}}{1+e^{\theta_i}} = p_i$ é a inversa da função *logit*; ou seja, o **expito (expit)**.

Dist. a posteriori

- Devido à estrutura de **independência condicional** deste modelo, é simples construir um algoritmo de simulação MCMC para gerar realizações a partir da distribuição *a posteriori* conjunta de (θ, μ, τ^2) .
- Condisional nos parâmetros μ e τ^2 , $\theta_1, \dots, \theta_n$ têm distribuições *a posteriori* independentes com θ_i distribuída de acordo com a densidade proporcional a

$$p(y_i|h(\theta_i)) \times g_1(\theta_i|\mu, \tau^2) = \text{Bin}(y_i|N_i, \text{expit}(\theta_i)) \times \phi(\theta_i|\mu, \tau^2),$$

em que $\phi(\cdot|\mu, \tau^2)$ é a função densidade normal.

Dist. a posteriori

- ▶ Então, combinando os estágios 2 e 3 do modelo, vê-se que os hiperparâmetros μ e τ^2 possuem as seguintes distribuições condicionais:

$$\mu|\theta, \tau^2, \mathbf{y} \sim N\left(\frac{\sigma_\mu^2}{\sigma_\mu^2 + \tau^2}\bar{\theta} + \frac{\tau^2}{\sigma_\mu^2 + \tau^2}\mu_0, \frac{\tau^2\sigma_\mu^2}{\sigma_\mu^2 + \tau^2}\right)$$

e

$$\tau^2|\theta, \mu, \mathbf{y} \sim Gal\left(a + \frac{n}{2}, b + \frac{1}{2} \sum_{i=1}^n [\theta_i - \mu]^2\right),$$

em que $\bar{\theta} = \frac{1}{n} \sum_{i=1}^n \theta_i$.

Dist. a posteriori



Dist. a posteriori



Esquema MCMC

Esquema MCMC

- ▶ Dado um valor inicial nos hiperparâmetros μ e τ^2 , use n passos de Metropolis-Hastings independentes para simular valores das taxas transformadas θ_i .
 - ▶ Podemos utilizar uma cadeia de **passeio aleatório** com a densidade de incremento $N(0, c\tau)$, em que o desvio padrão c é parâmetro de **tuning**.
- ▶ Em seguida, dados os valores simulados de θ_i , simule μ e τ^2 das distribuições *a posteriori* gama invertida e normal, em que se está condicionando aos valores simulados mais recentemente.
- ▶ Este ciclo simula uma cadeia de Markov que converge para a distribuição *a posteriori* conjunta de θ , μ e τ^2 .
 - ▶ Mais uma vez estamos utilizando o **amostrador de Gibbs com passos de M-H** (aqui o **M-H passeio aleatório**).
- ▶ Após descartar um conjunto de iterações de burn-in, a amostra simulada restante é tomada como uma amostra da distribuição *a posteriori* conjunta.

(M-H passeio aleatório)

- ▶ Seja a distribuição proposta, $q(y|x) = q(y|x)$ tal que

$$y = x + \varepsilon,$$

em que ε é uma densidade de probabilidade simétrica em 0.

- ▶ Dada esta definição, temos que

$$q(y|x) = f(\varepsilon)$$

e

$$q(x|y) = f(-\varepsilon) = f(\varepsilon).$$

(M-H passeio aleatório)

- ▶ Porque a proposta $q(y|x)$ é simétrica em x e y , a probabilidade de aceitação do Metropolis-Hastings $\rho(x,y)$ simplifica

$$\begin{aligned}\rho(x,y) &= \min \left\{ \frac{g(y)q(x|y)}{g(x)q(y|x)}, 1 \right\} \\ &= \min \left\{ \frac{g(y)}{g(x)}, 1 \right\}.\end{aligned}$$

(M-H passeio aleatório)

Dado o estado atual x , o algoritmo de Metropolis-Hastings procede da seguinte forma:

1. Simular $\varepsilon \sim f$ e faça $y = x + \varepsilon$.
2. Calcule a probabilidade de aceitação $\rho(x, y) = \min \left\{ \frac{g(y)}{g(x)}, 1 \right\}$.
3. Aceite y com probabilidade $\rho(x, y)$, caso contrário, continue em x .

Deve-se notar que esta forma do algoritmo Metropolis-Hastings era a forma original do **algoritmo Metropolis**.

Implementação em R

Implementação em R

- ▶ Considere o uso do algoritmo MCMC básico descrito na seção anterior com os valores dos hiperparâmetros definidos em $\mu_0 = 0$, $\sigma_\mu^2 = 1.000$, $a = 5$ e $b = 1$.
 - ▶ Esses valores refletem crenças *a priori* relativamente **vagas** sobre a localização dos parâmetros de segundo estágio.
- ▶ A seguir, carregamos os dados do arquivo Tsutakawa1985.txt.

Implementação em R

```
library(readr)
library(dplyr)

taxasMiss <- read_delim(
  file = here::here("dados",
                    "Tsutakawa1985.txt"),
  delim = "\t", escape_double = FALSE,
  trim_ws = TRUE)

taxasMiss

## # A tibble: 84 x 3
##   Cidade      N      y
##   <dbl> <dbl> <dbl>
## 1 1     98066  99
## 2 2     53637  54
## 3 3     46394  80
## 4 4     12890  17
## 5 5     10975  11
## 6 6     7436   13
## 7 7     3814   3
## 8 8     3461   2
```

Implementação em R

```
##   9      9  3349      1
## 10     10  3215      1
## # ... with 74 more rows
```

Implementação em R

```
library(invgamma)

# Configuração

mu_0 <- 0
sigma2_mu <- 1000
a <- 5
b <- 1
c_T <- 1.5

n <- length(taxasMiss$y)
M <- 10000
burnin <- 10000
k <- 10

cadeia_post <- matrix(0, nrow = M, ncol = n + 2)
colnames(cadeia_post) <- c(paste0("theta_", 1:n), "mu", "tau2")

# Valores iniciais
theta <- log( (taxasMiss$y + 1/2)/(taxasMiss$N - taxasMiss$y + 1/2) )
mu <- 0
tau2 <- 1

cadeia_post[1,] <- c(theta, mu, tau2)
```

Implementação em R

```
# Amostrador de Gibbs (burnin)

for (t in 1:burnin){

  # Passos de M-H passeio aleatório
  theta_cand <- theta +
    rnorm(n = n, mean = rep(0, n), sd = rep(c_T, n))

  razao_a <- ( dbinom(x = taxasMiss$y, size = taxasMiss$N,
    prob = (exp(theta_cand)/(1 + exp(theta_cand))) ) *
    dnorm(x = theta_cand, mean = mu, sd = sqrt(tau2)) )/
  ( dbinom(x = taxasMiss$y, size = taxasMiss$N,
    prob = (exp(theta)/(1 + exp(theta))) ) *
    dnorm(x = theta, mean = mu, sd = sqrt(tau2)) )

  rho <- apply(X = data.frame(razao_a),
    MARGIN = 1,
    FUN = function(x){min(x, 1)})

  u <- runif(n = n, min = 0, max = 1)
  theta <- ifelse(u <= rho, theta_cand, theta)

  mu <- rnorm(n = 1,
    mean = (sigma2_mu/(sigma2_mu + tau2)) * mean(theta) +
      (sigma2_mu/(sigma2_mu + tau2)) * mu_0,
    sd = sqrt( (sigma2_mu*tau2)/(sigma2_mu + tau2) ) )

  tau2 <- rinvgamma(n = 1,
    shape = a + n/2,
    rate = b + (1/2) * sum( (theta - mu)^2 ))
}

}
```

Implementação em R

```
for (t in 1:(k*M)){
  # Passos de M-H passeio aleatório
  theta_cand <- theta +
    rnorm(n = n, mean = rep(0, n), sd = rep(c_T, n))

  razao_a <- ( dbinom(x = taxasMiss$y, size = taxasMiss$N,
    prob = (exp(theta_cand)/(1 + exp(theta_cand))) ) *
    dnorm(x = theta_cand, mean = mu, sd = sqrt(tau2)) )/
  ( dbinom(x = taxasMiss$y, size = taxasMiss$N,
    prob = (exp(theta)/(1 + exp(theta)))) ) *
    dnorm(x = theta, mean = mu, sd = sqrt(tau2)) )







  rho <- apply(X = data.frame(razao_a),
    MARGIN = 1,
    FUN = function(x){min(x, 1)})
  u <- runif(n = n, min = 0, max = 1)
  theta <- ifelse(u <= rho, theta_cand, theta)

  mu <- rnorm(n = 1,
    mean = (sigma2_mu/(sigma2_mu + tau2)) * mean(theta) +
      (sigma2_mu/(sigma2_mu + tau2)) * mu_0,
    sd = sqrt( (sigma2_mu*tau2)/(sigma2_mu + tau2) ) )



  tau2 <- rinvgamma(n = 1,
    shape = a + n/2,
    rate = b + (1/2) * sum( (theta - mu)^2 ) )

  if (t %% k == 0) {cadeia_post[(t/k),] <- c(theta, mu, tau2)}
}
```



Implementação em R



Implementação em R





Implementação em R



Implementação em R

- E os p_i ?



Implementação em R

```
# Resumo da distribuição  
# a posteriori das taxas de scram

p_post <- data.frame(  
  cidade = factor(taxasMiss$Cidade),  
  y = taxasMiss$y,  
  N = taxasMiss$N,  
  EMV = taxasMiss$y/taxasMiss$N,  
  media = colMeans( exp(cadeia_post[,1:n])/(1 + exp(cadeia_post[,1:n])) ) )

p_post$li95 <- apply(X = exp(cadeia_post[,1:n])/(1 + exp(cadeia_post[,1:n])),  
                      MARGIN = 2,  
                      FUN = quantile, probs = 0.025)

p_post$ls95 <- apply(X = exp(cadeia_post[,1:n])/(1 + exp(cadeia_post[,1:n])),  
                      MARGIN = 2,  
                      FUN = quantile, probs = 0.975)


head(p_post)
```

Implementação em R

```
##          cidade  y      N        EMV       media      li95      ls95
## theta_1      1 99 98066 0.001009524 0.0010078268 0.0008151985 0.001218555
## theta_2      2 54 53637 0.001006768 0.0010035848 0.0007577165 0.001291516
## theta_3      3 80 46394 0.001724361 0.0017197524 0.0013602576 0.002117783
## theta_4      4 17 12890 0.001318852 0.0013076135 0.0007665179 0.002002235
## theta_5      5 11 10975 0.001002278 0.0009972582 0.0005024144 0.001671299
## theta_6      6 13  7436 0.001748252 0.0017082838 0.0009047188 0.002789167
```

Implementação em R

Estimativas de Taxa de óbito por câncer de estômago em homens com idades entre 45 e 64 anos das 84 maiores cidades do Missouri (média a posteriori e intervalo de credibilidade de 95%; *EMV em vermelho)



Implementação em R

- ▶ Note que para as cidades menores, estimativas mais precisas são obtidas quando estas tomam emprestado informações das demais cidades.
 - ▶ Este é chamado de “**borrowing strength**” nos modelos bayesianos hierárquicos.

Para casa

- ▶ Rodar os códigos dos exemplos de aula.
 - ▶ Trazer as dúvidas para o Fórum Geral do Moodle e para a próxima aula.

Próxima aula

- ▶ OpenBugs e Jags.

Por hoje é só!

Bons estudos!

